

1. Clustering (Agrupamiento)

TEMA 1 DE 6

El clustering es el proceso de agrupar un conjunto de objetos de tal manera que los objetos en el mismo grupo (llamado clúster) sean más similares entre sí que con los de otros grupos. El objetivo es encontrar una estructura intrínseca en los datos no etiquetados.

K-MEANS

DBSCAN

CLUSTERING JERÁRQUICO

Concepto

Es uno de los algoritmos de clustering más populares y simples. Su objetivo es dividir n observaciones en k clústeres, donde cada observación pertenece al clúster con la media (centroide) más cercana. El número de clústeres, k , debe ser especificado de antemano.


Funcionamiento






1. Se eligen k centroides iniciales (a menudo al azar).
2. Se asigna cada punto de dato al centroide más cercano.
3. Se recalculan los centroides como la media de todos los puntos asignados a ese clúster.
4. Se repiten los pasos 2 y 3 hasta que los centroides ya no cambien significativamente o se alcance un número máximo de iteraciones.

Consideraciones

Sensible a la elección inicial de centroides y a la escala de los datos. Asume que los clústeres son esféricos y de tamaño similar.

Figura 1. Evolución del algoritmo K-means para agrupar datos en 3 clusters diferentes. Los centroides son seleccionados inicialmente al azar, y evolucionan hasta minimizar la distancia promedio de los puntos al cluster al que están asignados.





(Density-Based Spatial Clustering of Applications with Noise)**Concepto**


Es un algoritmo de clustering basado en densidad. Agrupa puntos que están densamente empaquetados, marcando como outliers los puntos que se encuentran solos en regiones de baja densidad. A diferencia de K-Means, no requiere especificar el número de clústeres de antemano y puede encontrar clústeres de formas arbitrarias.

Parámetros Clave


Eps (distancia máxima entre dos muestras para que una se considere vecina de la otra) y min_samples (número mínimo de muestras en una vecindad para que un punto se considere un punto central).

Figura 2. Algoritmo DBSCAN, el algoritmo discrimina los puntos como puntos núcleo (los que tienen más vecinos dentro de un radio específico), puntos frontera (los que están conectados a puntos núcleo pero no tienen tantos vecinos) y puntos de ruido (que no tienen vecinos y no están conectados a los puntos core). Con base en esta distinción y las conexiones entre puntos, se establecen los clústeres finales.

Funcionamiento del Algoritmo DBSCAN (Conceptual)



Funcionamiento del Algoritmo DBSCAN (Conceptual)



K-MEANS

DBSCAN

CLUSTERING JERÁRQUICO

Concepto

Crea una jerarquía de clústeres que puede ser representada como un árbol (dendrograma). Hay dos enfoques principales:


- **Aglomerativo (Bottom-up):** comienza con cada punto como su propio clúster y fusiona progresivamente los clústeres más cercanos hasta que solo queda un clúster o se alcanza un criterio de parada.
- **Divisivo (Top-down):** comienza con todos los puntos en un solo clúster y los divide recursivamente en clústeres más pequeños.

Ventajas


No requiere especificar el número de clústeres de antemano; el dendrograma permite visualizar la estructura jerárquica.

Figura 3. Clústering jerárquico aglomerativo (Bottom-Up). En este contexto, los puntos más cercanos se van aglomerando para formar clústeres cada vez más grande. El dendrograma que se genera permite determinar un punto de corte para establecer el número de clústeres final.

Funcionamiento del Clustering Jerárquico Aglomerativo



Funcionamiento del Clustering Jerárquico Aglomerativo



1.1. Evaluación de Algoritmos de Clustering


TEMA 2 DE 6

Una vez que hemos aplicado un algoritmo de clustering, surge una pregunta fundamental: ¿qué tan buenos son los clústeres que hemos encontrado? Evaluar la calidad del clustering no siempre es sencillo, ya que, por definición, no tenemos etiquetas de "verdad fundamental" (ground truth) en el aprendizaje no supervisado. Sin embargo, existen diversas métricas que nos ayudan a cuantificar la calidad de la partición de los datos. Estas métricas se pueden dividir en dos categorías principales: internas y externas.

Métricas de Evaluación Interna:

Estas métricas evalúan la calidad de la estructura de los clústeres basándose únicamente en la información intrínseca de los datos y la partición generada (sin usar etiquetas externas). El objetivo general es medir qué tan compactos son los clústeres (puntos dentro de un clúster están cerca entre sí) y qué tan bien separados están los diferentes clústeres.

Coeficiente de Silueta (Silhouette Coefficient)









Concepto: Mide qué tan similar es un objeto a su propio clúster (cohesión) en comparación con otros clústeres (separación). El coeficiente de silueta para un único punto se calcula como $(b-a)/\max(a,b)$, donde a es la distancia promedio del punto a los otros puntos en su mismo clúster, y b es la distancia promedio del punto a los puntos en el clúster más cercano al que no pertenece.

Rango: Varía de -1 a +1. Un valor cercano a +1 indica que el punto está bien agrupado en su clúster y lejos de otros clústeres. Un valor cercano a 0 indica que el punto está cerca del límite entre dos clústeres. Un valor cercano a -1 indica que el punto podría estar mal asignado a ese clúster.

El Coeficiente de Silueta promedio para todo el conjunto de datos es una medida global de la calidad del clustering.

Figura 4. Evolución del coeficiente de silueta para diferentes numeros de clústeres. El valor se maximiza cuando se escogen 4 clústeres

Análisis del Coeficiente de Silueta para K-Means



2

Índice de Davies-Bouldin (Davies-Bouldin Index)

Concepto: Se define como la similitud promedio entre cada clúster y su clúster más similar, donde la similitud es una medida que compara la distancia entre clústeres con el tamaño de los propios clústeres. Se busca minimizar este índice.

Rango: Valores más bajos indican una mejor partición (clústeres más compactos y mejor separados). Un valor de 0 es el más bajo posible.

3

Índice de Calinski-Harabasz (Calinski-Harabasz Index / Variance Ratio Criterion)

Concepto: Se define como la razón entre la suma de la dispersión entre clústeres y la dispersión intra-clúster para todas las k particiones. Una puntuación más alta generalmente indica clústeres más densos y mejor separados.

Rango: Valores más altos son mejores.

2. Reducción de Dimensionalidad

TEMA 3 DE 6

En muchos conjuntos de datos del mundo real, tenemos un gran número de variables (dimensiones). Esto puede llevar a problemas como la "maldición de la dimensionalidad", mayor complejidad computacional y dificultad para visualizar los datos. La reducción de dimensionalidad busca reducir el número de variables mientras se conserva la mayor cantidad de información relevante posible.

ANÁLISIS DE COMPONENTES PRINCIPALES

T-SNE

(PCA - Principal Component Analysis):

Concepto

Es una técnica lineal muy popular para la reducción de dimensionalidad. PCA transforma los datos a un nuevo conjunto de variables (componentes principales) que son combinaciones lineales de las variables originales y no están correlacionadas entre sí. Estos componentes se ordenan por la cantidad de varianza original que explican.

Objetivo

Se seleccionan los primeros k componentes principales que capturan la mayor parte de la varianza, reduciendo así la dimensionalidad.


Usos

Visualización de datos de alta dimensión (proyectando a 2D o 3D), preprocesamiento para otros algoritmos de ML, compresión de datos.





Consideraciones: Sensible a la escala de los datos (se recomienda estandarizarlos antes). Asume relaciones lineales.

Figura 5. Análisis de componentes principales en 2 dimensiones. En el paso 2 se encuentra que la componente PC1 contiene el 92.4% de la varianza de los datos. Si se proyectan todos los datos a esta componente el problema pasa a ser un problema en 1D.

Funcionamiento del Análisis de Componentes Principales (PCA)



Funcionamiento del Análisis de Componentes Principales (PCA)



(t-distributed Stochastic Neighbor Embedding)**Concepto**

Es una técnica no lineal de reducción de dimensionalidad especialmente útil para la visualización de conjuntos de datos de alta dimensionalidad en espacios de baja dimensión (normalmente 2D o 3D). t-SNE modela la similitud entre puntos de datos en el espacio de alta dimensión y trata de encontrar una incrustación de baja dimensión que preserve estas similitudes.

Fortalezas

Muy bueno para revelar la estructura de clústeres locales en los datos.

Consideraciones

Es computacionalmente intensivo, especialmente con muchos datos. Los resultados pueden variar con los hiperparámetros (ej. perplexity). Las distancias entre clústeres en el mapa de baja dimensión no siempre son significativas globalmente.

3. Detección de Anomalías

TEMA 4 DE 6

La detección de anomalías (o detección de outliers) se refiere al problema de encontrar patrones en los datos que no se conforman con el comportamiento esperado. Estas anomalías pueden indicar errores en los datos, eventos raros o comportamientos fraudulentos.

ISOLATION FOREST

LOCAL OUTLIER FACTOR (LOF)

Concepto

Es un algoritmo eficiente para la detección de anomalías basado en árboles. Funciona aislando observaciones mediante la partición aleatoria del espacio de características. La idea es que las anomalías, al ser "pocas y diferentes", son más susceptibles de ser aisladas en menos particiones que los puntos normales.

Ventajas

Funciona bien en conjuntos de datos de alta dimensionalidad y no asume una distribución particular de los datos.

ISOLATION FOREST

LOCAL OUTLIER FACTOR (LOF)

Concepto

Es un algoritmo que calcula una puntuación de anomalía para cada punto de dato basándose en la densidad local de sus vecinos. Los puntos que tienen una densidad considerablemente menor que sus vecinos son considerados outliers.

Funcionamiento

Compara la densidad local de un punto con las densidades locales de sus vecinos.